


Correction du Partiel : Analyse des données quantitatives
Année : 2025/2026
Track : Anglo

Exercice 1 (3 points)

FeelWell, une entreprise spécialisée dans les solutions numériques de bien-être, a lancé une nouvelle version de son application mobile il y a trois mois. Afin d'évaluer l'impact de cette mise à jour, l'équipe marketing a analysé les notes de satisfaction globale attribuées par 480 utilisateurs sur une échelle de 10 points (1 = très insatisfait, 10 = très satisfait).



L'équipe chargée des données a ensuite généré le graphique ci-dessus à l'aide de Jamovi. Vous devez :

1. L'identifier, le nommer et le décrire en termes d'apparence générale (forme, symétrie et dispersion). (1,5 point)

- **Graphique** : les notes de satisfaction variables sur une échelle de 1 à 10. Il s'agit d'une donnée quantitative, le graphique approprié est donc un **histogramme**.
- **Apparence générale** : unimodale (un seul pic) avec **la fréquence la plus élevée : 5-6**.
- **Forme et symétrie** : la distribution est proche d'une forme **symétrique**
- **Dispersion** : la plupart des notes sont concentrées entre 4 et 7, et la **dispersion est modérée**

2. Indiquez la relation attendue entre la moyenne, la médiane et le mode si la distribution est parfaitement symétrique. (0,5 point)

Moyenne = Médiane = Mode. Dans ce cas, nous pouvons en déduire que la forme de la distribution est symétrique (ou en forme de cloche).

3. Expliquez pourquoi il faut être prudent lorsqu'on utilise la moyenne comme mesure représentative de la satisfaction et donnez un exemple de situation où cela pourrait être trompeur. (1 point)

- La moyenne est **sensible aux valeurs extrêmes** et peut être trompeuse lorsque la distribution est asymétrique (ou s'il existe des sous-groupes distincts).
- Si la plupart des utilisateurs déclarent être assez satisfaits (6-7) de la nouvelle version de l'application, mais qu'un petit groupe d'utilisateurs insatisfaits lui attribue des notes très faibles (1-2) en raison de problèmes techniques, la note moyenne de satisfaction peut baisser, suggérant une satisfaction modérée, même si la majorité des utilisateurs sont satisfaits. Dans ce cas, la médiane fournit une mesure plus représentative de la satisfaction globale.

Exercice 2 (8 points)

1. La même entreprise, FeelWell, cherche désormais à comprendre les relations entre les habitudes d'utilisation des applications par les utilisateurs, leur état psychologique et leurs contributions financières.
2. L'équipe chargée des données a mené une enquête auprès de 480 utilisateurs actifs afin d'examiner comment certaines dimensions spécifiques de l'utilisation et de la perception influencent les dépenses mensuelles dans l'application (abonnements premium, achats de contenu, services personnalisés).

Les variables mesurées sont les suivantes :

Variable	Type	Description
Utilisation (heures)	...	Temps moyen passé chaque semaine sur l'application (en heures)
Engagement	...	Score d'engagement numérique (0-100) mesurant la fréquence et l'intensité de l'interaction avec les fonctionnalités de l'application
Stress	...	Niveau de stress perçu (1 = très faible, 10 = très élevé)
Satisfaction	...	Score de satisfaction global (1-10)
Dépenses (€)	...	Montant mensuel dépensé sur l'application

Variables	Utilisation (heures)	Engagement	Stress	Satisfaction
Utilisation (heures)				
Engagement	0.66**			
Stress	0.29**	0.41**		
Satisfaction	0.51**	0.63**	-0.39**	
Dépenses (€)	0.62**	0.68**	0.16*	0.55**

(**p-value < .001; * p-value < .05)

Questions

1. Quels tests statistiques sont utilisés dans ce contexte ? Justifiez votre choix. (0,5 point)

• Toutes les variables sont quantitatives et continues, et l'objectif est d'examiner la force et la direction des relations linéaires entre l'utilisation, les perceptions, les états psychologiques et les dépenses. Nous utilisons le **test de corrélation de Pearson**.

2. Interprétez trois relations fortes observées et expliquez leur importance pour la start-up. Formulez les hypothèses correspondantes. (2,5 points)

Relation 1 : Engagement vs dépenses

H0 : Il n'y a pas de relation linéaire (pas de corrélation) entre l'engagement et les dépenses.

H1 : Il existe une relation linéaire significative (corrélation significative) entre l'engagement et les dépenses.

- Résultat : **$r = 0,68$** , $p < 0,001$
- Décision : Puisque $p < 0,05$, H0 est rejetée et H1 est acceptée.
- Interprétation : Il existe une corrélation forte et positive entre l'engagement et les dépenses. Les utilisateurs plus engagés sont plus susceptibles de s'abonner à des fonctionnalités premium et d'acheter du contenu supplémentaire, ce qui fait de l'engagement un facteur clé de revenus pour la start-up.

Relation 2 : Utilisation (heures) vs dépenses

H0 : Il n'y a pas de relation linéaire (pas de corrélation) entre le temps d'utilisation et les dépenses.

H1 : Il existe une relation linéaire significative (corrélation significative) entre le temps d'utilisation et les dépenses.

- Résultat : **$r = 0,62$** , $p < 0,001$

- Décision : puisque $p < 0,05$, H_0 est rejetée et H_1 est acceptée.
- Interprétation : il existe une corrélation forte et positive entre le temps d'utilisation et les dépenses. Les utilisateurs qui passent plus de temps sur l'application ont tendance à dépenser plus d'argent, probablement en raison d'une exposition plus importante aux services payants et à la valeur perçue.

Relation 3 : Satisfaction vs Engagement

H_0 : Il n'y a pas de relation linéaire (pas de corrélation) entre la satisfaction et l'engagement.

H_1 : Il existe une relation linéaire significative (corrélation significative) entre la satisfaction et l'engagement.

- Résultat : $r = 0,63$, $p < 0,001$
- Décision : Puisque $p < 0,05$, H_0 est rejetée et H_1 est acceptée.
- Interprétation : il existe une corrélation forte et positive entre la satisfaction et l'engagement. Les utilisateurs plus satisfaits interagissent plus fréquemment et plus profondément avec l'application, renforçant ainsi la création de valeur à long terme pour la start-up.

3. Identifiez une relation trompeuse et expliquez pourquoi elle pourrait conduire à une erreur de gestion. (1 point)

Relation : stress vs dépenses

- Résultat observé : $r = 0,16$ et $p < 0,05$.
- Pourquoi cela est trompeur : bien que la relation soit statistiquement significative, la corrélation est très faible, ce qui indique un effet pratique négligeable.
- Risque d'erreur managériale : les managers pourraient conclure à tort qu'une augmentation du stress des utilisateurs entraîne une augmentation des dépenses. Une telle interprétation néglige la faiblesse de l'effet et pourrait conduire à des décisions préjudiciables, telles que la mise en place de mécanismes basés sur la pression qui réduisent la satisfaction et nuisent à la fidélité à long terme des clients.

4. Que signifie une relation négative dans le contexte de la fidélité des clients ? (1 point)

Dans cette étude, la corrélation négative entre le stress et la satisfaction ($r = -0,39$) indique qu'un stress perçu plus élevé est associé à une satisfaction plus faible. La satisfaction étant un facteur clé de la fidélité des clients, un stress accru peut réduire cette fidélité.

5. Quelles recommandations managériales proposeriez-vous ? (2 points)

- Renforcer l'engagement des utilisateurs, car il est fortement et positivement lié aux dépenses ($r = 0,68$). L'amélioration des fonctionnalités interactives et personnalisées peut augmenter les revenus.
- Encourager le temps d'utilisation de l'application, car une utilisation plus intensive est associée à des dépenses plus élevées ($r = 0,62$), en promouvant des expériences utilisateur régulières et à valeur ajoutée.
- Réduire les facteurs de stress dans l'application, car le stress a un impact négatif sur la satisfaction ($r = -0,39$), ce qui peut affaiblir la fidélité des clients et la valeur à long terme.
- Éviter de s'appuyer sur des relations faibles (stress-dépenses, $r = 0,16$), car elles ont une pertinence managériale limitée.

6. Si vous deviez approfondir cette analyse, quelle méthode statistique complémentaire suggèreriez-vous pour tester les effets combinés de ces variables sur les dépenses ? (1 point)

Méthode : **régression linéaire multiple**

- Variable prédite (ou variable dépendante) = dépenses.

- Variables prédictives (ou variables indépendantes) : utilisation, engagement, stress et satisfaction

Justification : la régression linéaire multiple teste l'effet combiné de toutes les variables sur les dépenses et estime la contribution unique de chaque variable prédictive (ou variable indépendante) tout en contrôlant les autres.

Exercice 3 (9 points)

Afin de mieux comprendre les facteurs influençant les dépenses de santé des ménages aux États-Unis, une étude a été menée. Les variables suivantes ont été prises en compte :

- Âge : âge du bénéficiaire principal
- Statut tabagique : fumeur/non-fumeur
- Nombre d'enfants
- Sexe : homme/femme

Prédicteur	Estimation	Erreur standard	t	p	Estimation standard
Ordonnée à l'origine	-2883,0	572,0	-5,040	< ,001	-
Âge	273,1	12,4	21,981	< ,001	0,317
Statut tabagique :					
Fumeur	23836,9	433,2	55,021	< ,001	1,968
Nombre d'enfants	486,2	144,8	3,358	< ,001	0,048
Sexe :					
Masculin	61,3	349,7	0,175	0,861	0,005

				Test de modèle général			
Modèle	R	R ²	R ² ajusté	F	ddl1	ddl2	p
1	0.851	0.724	0.723	873	4	1333	< .001

Questions

1. Quelle méthode est appliquée ? Justifiez votre réponse. (0,5 point)

La variable dépendante (dépenses de santé des ménages) est continue, et l'analyse vise à estimer les effets simultanés de plusieurs prédicteurs (quantitatifs et qualitatifs) sur ce résultat.

2. Quelles variables ont un impact significatif sur les dépenses de santé ? Interprétez-les et expliquez-les. Le niveau de risque est de 5 % (2,5 points).

- Âge ; $B = 273,1$, $p < 0,001$ = significatif

Interprétation : toutes les autres variables étant constantes, chaque année supplémentaire augmente les dépenses de santé des ménages de 273,10 dollars en moyenne. Cela reflète les besoins accrus en matière de soins de santé à mesure que les individus vieillissent.

- Tabagisme (fumeur vs non-fumeur), $B = 23\,836,9$, $p < 0,001$ = significatif

Interprétation : le fait d'être fumeur est associé à une augmentation moyenne de 23 836,90 \$ des dépenses de santé par rapport à un non-fumeur, toutes choses égales par ailleurs. Le tabagisme augmente donc considérablement les coûts des soins de santé.

- Nombre d'enfants, $B = 486,2$, $p < 0,001$ = significatif

Interprétation : chaque enfant supplémentaire augmente les dépenses de santé du ménage de 486,20 \$ en moyenne, ce qui reflète des besoins plus élevés en matière de soins de santé pour la famille.

- Sexe (homme vs femme), $B = 61,3$, $p = 0,861 > 0,05$. non significatif

Interprétation : le sexe n'a pas d'effet statistiquement significatif sur les dépenses de santé du ménage.

3. Quelle variable a le plus d'influence sur les dépenses de santé ? (1 point)

L'estimation standardisée la plus élevée est associée au tabagisme ($\beta = 1,968$), ce qui indique que le tabagisme a l'influence relative la plus forte sur les dépenses de santé parmi tous les prédicteurs du modèle. Les coefficients standardisés étant exprimés sur une échelle

commune, ils permettent une comparaison directe et significative de l'importance relative des prédicteurs mesurés dans différentes unités.

4. Interprétez la qualité globale du modèle. Est-elle suffisamment élevée pour permettre une prédiction ? (1 point)

- Le modèle est statistiquement significatif ($F = 873$, $p < 0,001$), ce qui indique que les prédicteurs expliquent conjointement les dépenses de santé.
- Le coefficient de détermination est élevé ($R^2 = 0,724$), ce qui signifie que 72,4 % de la variance des dépenses de santé est expliquée par le modèle.
- Conclusion : la qualité globale du modèle est très élevée et suffisante pour permettre une prédiction fiable.

5. Proposez deux recommandations managériales ou opérationnelles cohérentes avec ces résultats. (2,5 points)

Agir sur le tabagisme en tant que principal facteur de coût

Étant donné que le tabagisme a l'effet le plus important sur les dépenses de santé (impact positif important et très significatif), les organismes de santé/assureurs devraient donner la priorité aux programmes de prévention et d'arrêt du tabagisme (**dépistage, conseil, incitations, prise en charge des thérapies de substitution nicotinique**).

6. Si vous deviez améliorer le modèle, quelles variables supplémentaires incluriez-vous et pourquoi ? (1,5 point)

- Niveau de revenu : pour tenir compte des différences d'accès aux services de santé et de capacité de paiement, qui influencent directement les dépenses de santé.
- Présence de maladies chroniques (par exemple, diabète, troubles cardiovasculaires) : pour prendre en compte les coûts médicaux à long terme et récurrents qui ne s'expliquent pas uniquement par l'âge.
- Caractéristiques de la couverture d'assurance maladie (type de régime, niveau de remboursement) : pour refléter les variations dans l'utilisation des soins de santé et le comportement en matière de dépenses.