

Relation entre deux variables

Rappel

Analyse descriptive univariée

Analyse d'une seule variable séparément des autres variables

Nature des variables

- Quantitative (discrète, continue)
- Qualitative (ordinaire, nominale)

Statistiques descriptives

- Indicateurs (tendance centrale, dispersion)
- Diagrammes (Histogramme, Diagramme en barres, Boxplot, etc)

Rappel

Les indicateurs de tendance centrale

- Moyenne
- Médiane
- Mode

Les indicateurs de dispersion

- Étendue
- Variance
- Écart-type
- Coefficient de variation

Objectifs de la séance

Apprendre à analyser la relation entre deux variables, selon leur nature :

1. Identifier la nature de la relation entre deux variables
2. Choisir le test statistique approprié
3. Lire et interpréter les sorties Jamovi
4. Transformer les résultats en recommandations managériales

Plan de la séance n°2

1. Introduction
2. Relation entre deux variables qualitatives
3. Relation entre deux variables quantitatives
4. Relation entre une variable quantitative et une variable qualitative

Introduction

Pourquoi analyser une relation ?

Prendre des décisions fondées sur les données

Exemples en entreprise :

- Les clients satisfaits achètent-ils plus ?
- L'âge influence-t-il la performance ?
- Le type de client est-il lié au taux d'abandon des clients ?

Types de relations possibles

- Relation entre deux variable Qualitatives ==> Association (Test de Khi-deux)
- Relation entre deux variable Quantitatives ==> Corrélation (Test de Pearson)
- Relation une variable Qualitative et une autre Quantitative ==> Comparaison (t-test)

Chaque type de relation a un test adapté

Exemple: Ressources Humaines

Question : l'ancienneté est-elle liée à la performance ?

Variables : ancienneté (quantitative), performance (quantitative)

Indicateur : corrélation

Analyser le diagramme de nuage de points (scatterplot) + Appliquer le test de Pearson

Relation entre deux variables qualitatives

Objectif

Comprendre si deux variables qualitatives ont un lien structurel ou si leur co-occurrence est simplement due au hasard.

Exemples:

- **Marketing** : les jeunes choisissent-elles davantage des boissons sucrées ?
- **RH** : les employés du service IT quittent-ils davantage l'entreprise ?
- **Service client** : le motif d'insatisfaction dépend-il du canal utilisé (téléphone, e-mail, chat) ?
- **Opérations** : les problèmes qualité touchent-ils certains types de produits plus que d'autres ?

Comment analyser deux variables qualitatives ?

Étape 1 : Construire un Tableau de contingence → Permet de visualiser la répartition des catégories.

Étape 2 : Visualiser → Diagramme en barres (juxtaposées, empilées)

Étape 3 : Tester statistiquement (test du Khi-deux) → Permet de déterminer si les différences observées sont statistiquement significatives.

Exemple: CaféEMN

Dataset CaféEMN_V2 (A télécharger sur Upward)

Question : La répartition hommes/femmes est-elle la même dans toutes les villes ?

Pourquoi cette question est pertinente ?

Une ville avec plus de clientes peut préférer certains produits

Les campagnes marketing peuvent être adaptées localement

Les préférences de boisson peuvent varier selon la structure du segment

- **Genre**: variable qualitative nominale
- **Ville**: variable qualitative nominale (15 villes)

Tableau de contingence

The screenshot shows a statistical software interface with a menu bar at the top containing 'Variables', 'Données', 'Analyses', and 'Editer'. The 'Analyses' menu is open, displaying several options: 'Exploration', 'Tests T', 'ANOVA', 'Régression', 'Fréquences', and 'Facteur'. The 'Fréquences' option is highlighted with a red box. A sub-menu for 'Fréquences' is also open, showing options for 'Test de proportion pour un échantillon', '2 Résultats' (Test binomial), 'N résultats' (Test d'ajustement du χ^2), 'Tables de contingence', 'Echantillons indépendants' (Test χ^2 d'association), 'Echantillons appariés' (Test de McNemar), and 'Régression log-linéaire'. The 'Echantillons indépendants' option is highlighted with a red box. In the background, a data table is visible with columns 'ID', 'Genre', and 'Age'.

	ID	Genre	Age
1	1	Femme	
2	2	Homme	
3	3	Femme	
4	4	Femme	
5	5	Femme	
6	6	Homme	
7	7	Homme	
8	8	Femme	
9	9	Femme	
10	10	Femme	
11	11	Femme	
12	12	Femme	

Tableau de contingence

En effectifs observés

Tables de contingence

Ville	Genre		Total
	Femme	Homme	
Angers	17	2	19
Bordeaux	16	20	36
Dijon	20	2	22
Grenoble	16	11	27
Lille	35	7	42
Lyon	21	26	47
Marseille	27	12	39
Montpellier	21	8	29
Nantes	13	15	28
Nice	10	4	14
Paris	74	24	98
Rennes	10	9	19
Rouen	12	7	19
Strasbourg	22	6	28
Toulouse	22	11	33
Total	336	164	500


Tableau de contingence

En pourcentages


Tables de contingence

Ville		Genre		Total
		Femme	Homme	
Angers	% par ligne	89.5 %	10.5 %	100.0 %
Bordeaux	% par ligne	44.4 %	55.6 %	100.0 %
Dijon	% par ligne	90.9 %	9.1 %	100.0 %
Grenoble	% par ligne	59.3 %	40.7 %	100.0 %
Lille	% par ligne	83.3 %	16.7 %	100.0 %
Lyon	% par ligne	44.7 %	55.3 %	100.0 %
Marseille	% par ligne	69.2 %	30.8 %	100.0 %
Montpellier	% par ligne	72.4 %	27.6 %	100.0 %
Nantes	% par ligne	46.4 %	53.6 %	100.0 %
Nice	% par ligne	71.4 %	28.6 %	100.0 %
Paris	% par ligne	75.5 %	24.5 %	100.0 %
Rennes	% par ligne	52.6 %	47.4 %	100.0 %
Rouen	% par ligne	63.2 %	36.8 %	100.0 %
Strasbourg	% par ligne	78.6 %	21.4 %	100.0 %
Toulouse	% par ligne	66.7 %	33.3 %	100.0 %
Total	% par ligne	67.2 %	32.8 %	100.0 %

Visualisation (Diagramme en barres empilées)



Visualisation (Diagramme en barres juxtaposée)



On commence à suspecter une association, mais ça reste visuel.

Il faut tester statistiquement pour conclure.

Test du Khi-deux

L'objectif du test

Répondre à la question suivante : Les différences observées entre groupes sont-elles dues au hasard ?

Démarche

1. Hypothèse: il n'y a aucune association entre les deux variables qualitatives
2. Calculer la probabilité d'observer nos données. Cette probabilité est appelée la p-value.
3. Nous fixons une valeur pour un seuil (par exemple, 0,05)
4. Si cette probabilité est inférieure à ce seuil $\implies$ nous disons qu'il y a probablement une association entre les deux variables.

Test du Khi-deux (formel)

Hypothèses

- **Hypothèse nulle H_0** : pas d'association (indépendance)
- **Hypothèse alternative H_1** : association entre les variables

Calculer la valeur p (p-value) de Khi-deux.

- Si $p < 0,05$, alors l'association est statistiquement significative
- Si $p \geq 0.05$, alors il n'y a pas de preuve suffisante d'association

Logique du test (l'analogie innocent / coupable)

Supposons que nous sommes des détectives:

Hypothèses

- **Hypothèse nulle H_0** : Le suspect est innocent.
- **Hypothèse alternative H_1** : Le suspect est coupable.

En statistique, nous commençons toujours par supposer l'innocence (H_0 est vraie) tant que les preuves ne sont pas assez fortes pour dire le contraire.

Logique du test (l'analogie innocent / coupable)

Lorsque nous recueillons des preuves (données), elles peuvent parfois être trompeuses : un innocent peut avoir l'air suspect juste par hasard.

Alors nous nous posons la question suivante :

“Si le suspect était vraiment innocent, quelle est la probabilité d'observer des preuves (données) aussi étranges que celles que j'ai collectées ?”

Cette probabilité, c'est exactement la **p-value**.

- **p-value** grande $\implies$ les preuves ne sont pas étonnantes si le suspect est innocent $\implies$ on ne l'accuse pas.
- **p-value** petite $\implies$ les preuves seraient très improbables si le suspect était innocent $\implies$ suspicion $\implies$ on envisage de rejeter l'innocence.

Logique du test (l'analogie innocent / coupable)

Relation entre deux variables quantitatives	L'analogie innocent / coupable
Hypothèse nulle H_0 : pas d'association (indépendance)	Hypothèse nulle H_0 : Le suspect est innocent.
Hypothèse alternative H_1 : association entre les variables	Hypothèse alternative H_1 : Le suspect est coupable

Test du Khi-deux

ddl: degré de la liberté de la statistique de khi-deux χ^2

Tests χ^2			
	Valeur	ddl	p
χ^2	47.6	14	< .001
N	500		

$p < 0,05$, alors l'association est statistiquement significative

Test V de Cramér

Un test de khi-deux statistiquement significatif confirme qu'il existe une association entre vos variables qualitatives:

Mais il ne révèle pas dans quelle mesure cette relation est significative ou forte en termes pratiques.

Le V de Cramér comble cette lacune en mesurant la force de l'association sur une échelle normalisée de 0 à 1, où 0 indique l'absence d'association et 1 représente une association parfaite.

Interprétation du V de Cramér

Comprendre l'importance du coefficient V de Cramér vous aide à communiquer la signification pratique de vos résultats. Utilisez ce guide pour interpréter les tailles d'effet dans vos recherches.

V de Cramér	Interprétation
0.00 to 0.10	Association très faible – pertinence pratique minimale
0.10 to 0.30	Association faible à modérée – effet perceptible mais modeste
0.30 to 0.50	Association modérée à forte – importance pratique considérable
Supérieur à 0.50	Association très forte – relation hautement significative

Test de chi-deux et le V de Cramér

Tests χ^2

	Valeur	ddl	p
χ^2	47.6	14	< .001
N	500		

Nominal

	Valeur
Coefficient Phi	NaN
V de Cramer	0.309

Conditions du Test de Khi-deux

Pour que le test soit valide :

- Observations indépendantes (un individu ne peut appartenir qu'à une seule classe)
- Échantillon suffisamment grand
- Effectifs attendus > 5 dans au moins 80% des cases

(Jamovi signale les problèmes)

Relation entre deux variables quantitatives

Objectif

Analyser si deux variables quantitatives évoluent ensemble, afin de :

- détecter des tendances
- comprendre des mécanismes
- soutenir la prise de décision

Exemples:

- **Ventes** : Chiffre d'affaires $\leftrightarrow$ Satisfaction régionale?
- **RH** : Performance $\leftrightarrow$ Ancienneté ?
- **CaféEMN** : Montant du ticket $\leftrightarrow$ Fréquence de visite ?



Pourquoi analyser deux variables quantitatives ?

Pour répondre à des questions clés :

- Les clients qui viennent plus souvent dépensent-ils plus ?
- Les salariés plus anciens performant-ils mieux ?
- Les magasins avec un meilleur Net Promoter Score (NPS) ont-ils un chiffre d'affaires plus élevé ?

Le nuage de points (scatterplot)

- Le nuage de points est le premier outil pour comprendre une relation entre deux variables quantitatives
- Permet d'observer la forme, la direction et la dispersion



Comment lire un scatterplot ?

- Relation positive : les variables augmentent ensemble
- Relation négative : l'une augmente, l'autre diminue
- Aucune relation : points dispersés
- Relation non linéaire : forme courbe

Corrélation de Pearson – Intuition

- Coefficient de corrélation de Pearson « r »
- Mesure la force et le sens d'une relation linéaire
- Valeurs entre -1 et +1
- L'intensité de la corrélation est la valeur absolue du coefficient r : $|r|$
- Plus $|r|$ est élevé, plus la relation est forte


Interprétation de l'intensité

- 0.00–0.20 → très faible
- 0.20–0.40 → faible
- 0.40–0.60 → modérée
- 0.60–0.80 → forte
- 0.80–1.00 → très forte

Exemple: CaféEMN

- 1- Choisir deux variables quantitatives (ex : âge $\leftrightarrow$ montant du ticket, satisfaction $\leftrightarrow$ montant du ticket)
- 2- Créer un scatterplot
- 3- Calculer le coefficient de corrélation de Pearson et
- 4- Répondre aux deux questions :
 - La relation est-elle positive, négative ou inexistante ?
 - Quelle recommandation proposeriez-vous au manager ?

Exemple: CaféEMN



Matrice de corrélation

	Montant_Ticket	Age
Montant_Ticket	—	
Age	0.194	—

Relation entre une variable quantitative et une variable qualitative

Relation entre une variable qualitative et une variable quantitative

Méthode principale : test t pour comparer deux moyennes

Applications: satisfaction selon le genre, ticket selon le type de client

À suivre dans la prochaine séance