

Relation entre deux variables
Analyse de la variance (ANOVA)

Rappel

Analyse descriptive bivariable

Analyse de la relation entre deux variables

Types de relations possibles

- Relation entre deux variable Qualitatives ==> **Association (Test de Khi-deux, V de Cramer)**
- Relation entre deux variable Quantitatives ==> **Corrélation (Test de Pearson)**
- Relation une variable Qualitative et une autre Quantitative ==> **Comparaison (t-test)**

Chaque type de relation a **un test d'hypothèse** adapté

Logique d'un test d'hypothèse

Test de relation entre deux variables	L'analogie innocent / coupable
Hypothèse nulle H_0 : pas de relation (indépendance) Hypothèse alternative H_1 : relation entre les variables	Hypothèse nulle H_0 : Le suspect est innocent. Hypothèse alternative H_1 : Le suspect est coupable

Rappel

Logique d'un test d'hypothèse

La probabilité p-value:

“Si le suspect était vraiment innocent, quelle est la probabilité d’observer les preuves (données) que j’ai collectées ?”

- **p-value** grande (généralement $> 0,05$) $\implies$ innocence (pas de relation).
- **p-value** petite $\implies$ on envisage de rejeter l’innocence (relation).

Plan de la séance n°3

1. Relation entre une variable quantitative et une variable qualitative
2. Analyse de la variance (ANOVA)

Relation entre une variable quantitative et une variable qualitative

Relation de comparaison

Relation entre une variable qualitative et une variable quantitative

Exemple : Relation entre la variable Performance et la variable Service

- Performance: variable quantitative
- Service: variable qualitative (deux valeurs possibles: service IT et service RH)
- Question: Les salariés du service IT ont-ils une performance moyenne plus élevée que ceux du service RH ?
- Réponse: Comparer la performance moyenne entre les deux groupes (service IT et service RH).

Le test t (test de Student)

Question : Les moyennes des deux groupes sont-elles réellement différentes, ou est-ce juste un hasard ?

Démarche du test t

1) Formuler les hypothèses

- **Hypothèse nulle H_0** : pas de différence (moyenne du groupe 1 = moyenne du groupe 2)
- **Hypothèse alternative H_1** : il y a une différence

2) Calculer la probabilité p-value (valeur donnée par l'outil informatique)

- Si $p\text{-value} \leq \text{seuil de rejet}$: il y a une différence statistiquement significative
- Si $p\text{-value} > \text{seuil de rejet}$: pas de différence

Test t: calcul de la probabilité p-value

C'est la probabilité d'observer la statistique t

La statistique t :

$$t = \frac{\mu_1 - \mu_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- Moyenne du groupe 1: μ_1
- Ecart-type du groupe 1: s_1
- Taille de l'échantillon: n_1

- Moyenne du groupe 2: μ_2
- Ecart-type du groupe 2: s_2
- Taille de l'échantillon: n_2

La probabilité p-value:

$$2 \times P(T \geq |t|)$$

Exemple: CaféEMN

Dataset CaféEMN_V2 (A télécharger sur Upward)

Question : comparer les moyennes du montant dépensé entre les deux groupes Homme et Femme ?

- **Genre (H/F)**: variable qualitative
- **Montant du ticket (€)**: variable quantitative

Réponse:

Première étape: observer les distributions (tracer le diagramme Boxplot – Boîte à moustaches)

Deuxième étape: appliquer le test t


Exemple: CaféEMN

The screenshot shows the CaféEMN software interface. The top navigation bar includes 'Variables', 'Données', 'Analyses' (highlighted with a red box), and 'Editer'. Below this, a row of icons represents different analysis types: 'Exploration' (highlighted with a red box), 'Tests T', 'ANOVA', 'Régression', 'Fréquences', and 'Facteur'. A dropdown menu is open under 'Exploration', showing 'Statistiques descriptives' (highlighted with a red box), 'Nuage de points', and 'Diagramme de Pareto'. The 'Statistiques descriptives' menu is also highlighted with a red box. The main workspace shows a list of variables on the left: 'Age', 'Ville', 'Fréquence_Visite', and 'Satisfaction'. On the right, the 'Variables' section contains 'Montant_Ticket' and the 'Séparer par' section contains 'Genre'.

The screenshot shows the 'Graphes' panel in the CaféEMN software interface. It contains two sections: 'Histogrammes' and 'Boîtes à moustaches'. In the 'Histogrammes' section, there are two checkboxes: 'Histogramme' (unchecked) and 'Densité' (unchecked). In the 'Boîtes à moustaches' section, there are two checkboxes: 'Boîte à moustaches' (checked) and 'Étiqueter les valeurs aberrantes' (unchecked).


Exemple: CaféEMN

Montant_Ticket



	Genre	Montant_Ticket
Moyenne	Femme	6.80
	Homme	6.91

Exemple: CaféEMN



Variables dépendantes

Montant_Ticket

Variable de groupage

Genre

Test t pour échantillons indépendants

Test t pour échantillons indépendants

		Statistique	ddl	p
Montant_Ticket	t de Student	-1.31	498	0.192

Note. $H_a: \mu_{\text{Femme}} \neq \mu_{\text{Homme}}$

p-value > 0,05: pas de différence

Le test t montre qu'il n'y a pas de différence significative entre les deux groupes

S'il existe une différence significative :

- Ajuster les offres marketing
- Adapter les prix ou promotions
- Comprendre les segments clients

Analyse de la variance (ANOVA)

Pourquoi une analyse de la variance ?

Nous savons déjà comment comparer entre deux variables: quantitative et qualitative (deux groupes)

Mais en entreprise :

Nous manipulons des variables qualitatives avec plus que deux groupes

Exemple

- La variable qualitative est la stratégie de marketing d'une entreprise
- Valeurs prises par cette variable (stratégie A/ stratégie B/ stratégie C)

Pourquoi une analyse de la variance ?

Démarche

Option 1: Multiplier les tests t

Comparer les stratégies deux à deux

==> inflation du risque d'erreur

Option 2: Analyse de la variance (ANOVA)

Généralisation du test t

Question centrale

La variabilité observée est-elle due aux groupes ou au hasard ?

Idée

ANOVA compare :

- la variabilité entre les groupes
- la variabilité à l'intérieur des groupes

Si la variabilité entre groupes est grande par rapport à la différence à l'intérieur des groupes

$\implies$ il y a une différence entre les groupes

Logique statistique de l'ANOVA

Décomposition de la variance

- Variance totale
- Variance expliquée (entre groupes)
- Variance résiduelle (intra-groupes)

Statistique de test

- Statistique : F
- $F = \text{Variance inter-groupes} / \text{Variance intra-groupes}$
- Plus F est grand, plus l'effet est probable

Test de l'ANOVA

Démarche du test

1) Formuler les hypothèses

- **Hypothèse nulle H_0** : toutes les moyennes sont égales
- **Hypothèse alternative H_1** : au moins une moyenne est différente

2) Calculer la probabilité p-value (valeur donnée par l'outil informatique)

- Si $p\text{-value} \leq \text{seuil de rejet}$: il y a une différence statistiquement significative
- Si $p\text{-value} > \text{seuil de rejet}$: pas de différence

L'ANOVA ne dit pas quels groupes diffèrent

ANOVA à un facteur (One-way ANOVA)

Quand l'utiliser ?

- Une variable quantitative
- Une seule variable qualitative à ≥ 3 modalités (groupes)

Exemples

- Ventes selon la politique de prix
- Performance selon le style de management
- Satisfaction selon le type de service

Exemple: politique de prix

Variable quantitative : Ventes mensuelles (€)



Variable qualitative : Politique de prix (Bas / Moyen / Premium)

Objectif managérial :

Identifier le positionnement prix le plus performant

JAMOVI – ANOVA à un facteur

Dataset **ANOVA_PRIX_VENTES** (A télécharger sur Upward)



JAMOVİ – ANOVA à un facteur

Choisir les options suivantes

Variances	Statistiques additionnelles
☒ Ne pas supposer l'égalité (pour le test de Welch)	☐ Tableau des statistiques descriptives
☒ Égalité supposée (test de Fisher)	☒ Graphes descriptifs
Valeurs manquantes	Vérifications des hypothèses
☒ Exclure les cas analyse par analyse	☒ Test d'homogénéité des variances
☐ Exclure les cas selon une liste	☐ Test de normalité
	☐ Graphe Q-Q

Anova unidirectionnelle

Anova unidirectionnelle

		F	ddl1	ddl2	p
Ventes	Welch	65.8	2	3.51	0.002
	Fisher	104	2	6	< .001

Vérifications des hypothèses

Test d'homogénéité des variances (test de Levene)

	F	ddl1	ddl2	p
Ventes	0.778	2	6	0.501

[3]

Lecture des résultats

Si p-value du test de Levene $> 0,05$:

==> il y a une homogénéité des variances

==> Lire les résultats du test de **Fisher**

Si le p-value $\leq 0,05$ ==> il y a une différence entre les politiques

Si p-value du test de Levene $\leq 0,05$:

==> il n'y a pas d'homogénéité des variances

==> Lire les résultats du test de **Welch**

Si le p-value $\leq 0,05$ ==> il y a une différence entre les politiques

JAMOVİ – ANOVA à un facteur

L'ANOVA ne dit pas quelles politiques diffèrent

Il faut utiliser un test post hoc (Test de Tukey)

Test post hoc	Statistiques
☐ Aucune	☒ Différence moyenne
☐ Games-Howell (variances inégales)	☒ Rapport de significativité
☒ Tukey (variances égales)	☐ Résultats du test (t et ddl)
	☐ Signaler les comparaisons significatives


JAMOVİ – ANOVA à un facteur

Résultats du test de Tukey

Test post-hoc de Tukey – Ventes

		Bas	Moyen	Premium
Bas	Différence moyenne	—	–190	–440
	valeur p	—	0.002	< .001
Moyen	Différence moyenne		—	–250
	valeur p		—	< .001
Premium	Différence moyenne			—
	valeur p			—

JAMOVİ – ANOVA à un facteur



ANOVA à deux facteurs (Two-way ANOVA)

Les décisions business dépendent rarement d'un seul facteur.

Exemple : la satisfaction des clients dépend du canal de vente et du programme de fidélité

- **Variable quantitative:** Satisfaction des clients
- **Variable qualitative n°1:** Canal de vente
- **Variable qualitative n°2:** Programme de fidélité

Trois questions statistiques

- Le canal influence-t-il la satisfaction ?
- La fidélité influence-t-elle la satisfaction ?
- L'effet du canal dépend-il de la fidélité ?

Exercice 1

Contexte

Une entreprise e-commerce analyse si le montant moyen du panier dépend du type de client.

- Variable quantitative : Montant du panier (€)
- Variable qualitative : Type de client (Nouveau, Régulier, Fidèle, Premium)

Exercice 1

Résultats Jamovi

Tableau ANOVA

- $F = 18,7$
- $p\text{-value} < 0.001$

Moyennes observées

- Nouveau : 32 €
- Régulier : 41 €
- Fidèle : 52 €
- Premium : 68 €

Post-hoc (Tukey)

- Tous les groupes sont significativement différents ($p < 0.01$)

Exercice 1

Questions

- Peut-on affirmer que le type de client influence le panier moyen ?
- Quel groupe est le plus stratégique ?
- Proposez 3 actions business concrètes.

Exercice 2

Contexte

Le service RH souhaite savoir si la performance moyenne des employés diffère selon leur service.

- **Variable quantitative** : Score de performance (0–100)
- **Variable qualitative** : Service (Marketing, Ventes, Finance, IT, RH)

Exercice 2

Résultats Jamovi

Tableau ANOVA

- $F = 9,85$
- $p\text{-value} < 0.001$

Moyennes observées

- IT : 82
- Finance : 78
- Ventes : 71
- Marketing : 69
- RH : 66

Post-hoc (Tukey)

- IT $\neq$ Marketing, RH, Ventes ($p < 0.01$)
- Finance $\neq$ RH ($p < 0.05$)

Exercice 2

Questions

- L'effet du service sur la performance est-il significatif ?
- Quels services se distinguent le plus ?
- Quelles décisions RH recommanderiez-vous ?